

CLASIFICACIÓN AUTOMÁTICA DE RESIDUOS

Juan Gómez Díaz

Aprendizaje profundo



Cartón

Vidrio

Metal

Papel

Plástico

Basura

¿POR QUÉ NECESITAMOS ESTO?

2.1

mil millones de toneladas
de residuos generados
cada año en el mundo

CLASIFICACIÓN MANUAL

- Lento y caro
- Alta tasa de error
- No escalable
- Dependencia humana

CLASIFICACIÓN AUTOMÁTICA

- Rápido y eficiente
- Alta precisión
- Escalable al 100%
- Consistente 24/7

OBJETIVO: Clasificador de residuos en 6 categorías — Cartón · Vidrio · Metal · Papel · Plástico · Basura

METODOLOGÍA Y DATASET

~2,500

imágenes reales

6

clases distintas

80/10/10

train / val / test

PIPELINE DEL SISTEMA

Imagen
de Residuo



Pre-
procesado




Modelo



Clasificación

Métrica principal: Accuracy = predicciones correctas / total de predicciones · También: Precision, Recall y F1-score por clase

EVOLUCIÓN DE MODELOS



0,45

Regresión Logística
(features lineales insuficientes)

0,6640

Random Forest
(sin relaciones espaciales)

0,8538

CNN desde cero
(representa patrones visuales)

0,9051

DenseNet121
(Transfer Learning)

RETOS Y PROBLEMAS ENCONTRADOS

Sobreajuste constante

Casi todos los modelos memorizaban el train (>99%) sin generalizar bien al test. Lo combatimos con Dropout en las capas densas, ReduceLROnPlateau para ajustar el learning rate automáticamente y EarlyStopping para restaurar el mejor checkpoint.

La clase 'Basura' es casi inclasificable

Es la clase más difícil de todas: agrupa objetos muy heterogéneos que no encajan en ninguna otra categoría, por lo que no tiene un patrón visual claro. Ningún modelo consigue superar el 80% de recall en ella, ni siquiera DenseNet121.

Más parámetros ≠ mejor resultado

Los Models 4 y 5 eran más grandes que el Model 3 pero rendían peor en test. Aumentar el ancho de red sin criterio no ayuda — la arquitectura y la regularización importan más que el número bruto de parámetros.

MEJOR MODELO: DenseNet121

0,9051

TEST ACCURACY

RESULTADOS POR CLASE

Clase	Precision	Recall	F1
Cartón	0.89	0.95	0.92
Vidrio	0.98	0.86	0.91
Metal	0.76	0.93	0.84
Papel	0.93	0.95	0.94
Plástico	1.00	0.88	0.93
Basura	0.83	0.77	0.80

Train: 0,9960

Val: 0,9289

Test: 0,9051

EVALUACIÓN DE ROBUSTEZ Y REPRODUCIBILIDAD

Se repitió el entrenamiento de los dos mejores modelos con 4 semillas distintas (42, 123, 7, 99) para estimar la variabilidad real del rendimiento.

EfficientNetB0 — Modelo 8

Semilla	Train	Val	Test
42	0,9990	0,9249	0,9012
123	0,9980	0,9012	0,8617
7	0,9985	0,9249	0,8775
99	0,9985	0,8893	0,8656
Media	0,9985	0,9101	0,8765

DenseNet121 — Modelo 9

Semilla	Train	Val	Test
42	0,9990	0,8972	0,9012
123	0,9990	0,8893	0,8854
7	0,9990	0,8893	0,8696
99	0,9990	0,8933	0,8972
Media	0,9990	0,8923	0,8883

CONCLUSIONES Y PRÓXIMOS PASOS

LO QUE LOGRAMOS

- 0.9051 de accuracy en test
- Validación con 4 semillas distintas
- De modelos lineales a Transfer Learning
- DenseNet121 como modelo final robusto
- Sistema reproducible y escalable

MEJORAS

- ↑ Data augmentation más agresivo
- ↑ Más imágenes de la clase 'Basura'
- ↑ Probar modelos mas eficientes

FINAL

